

# FICHE TECHNIQUE — Prédiction de la Qualité de l'Air dans les Villes Marocaines

Réalisé par BOUJAJ Imane, WARDI Safae

Pipeline ML complet : collecte API → préparation → modélisation → apprentissage fédéré

## OBJECTIF DU PROJET

Construire un système de prédiction de la qualité de l'air (PM2.5 et AQI) à partir de données réelles collectées via API dans 6 villes marocaines, en comparant une approche centralisée et une approche fédérée.

## STACK TECHNIQUE

- Python · pandas, numpy, scikit-learn
- Collecte : requests + API OpenWeatherMap (Weather + Air Pollution)
- Visualisation : matplotlib, seaborn
- Fédéré : implémentation FedAvg manuelle + framework Flower (flwr) sur backend Ray
- Persistance : joblib (modèles & encodeurs .pkl)

## DONNÉES COLLECTÉES

- Villes : Casablanca, Rabat, Marrakech, Fès, Tanger, Agadir
- Période : 25 avril – 9 mai 2026 · collecte horaire avec reprise automatique sur incident (checkpoint JSON)
- 996 enregistrements · 21 variables brutes (météo + polluants) ·

## PRÉPARATION DES DONNÉES

- 3 doublons supprimés · 3 cycles incomplets reconstitués par interpolation linéaire (39 valeurs)
- Encodage des villes (LabelEncoder) · normalisation StandardScaler (9 variables numériques)
- 12 features finales retenues · cibles : PM2.5 (régression) et AQI (classification, 3 classes : Bon 3,9 % / Moyen 62,3 % / Dégradé 33,7 %)

## MODÉLISATION — RÉGRESSION PM2.5

| Modèle         | MAE   | R <sup>2</sup> |
|----------------|-------|----------------|
| Linéaire       | 0,839 | 0,802          |
| Random Forest  | 0,328 | 0,966          |
| Arbre Décision | 0,498 | 0,908          |

→ Random Forest retenu (meilleur compromis biais/variance).

## MODÉLISATION — CLASSIFICATION AQI

- Random Forest Classifier · Accuracy = 98,5 % · F1 pondéré = 0,983
- Point d'attention : rappel = 0,62 sur la classe minoritaire « Bon » (8 échantillons test)

## APPRENTISSAGE FÉDÉRÉ (BONUS)

- 6 clients fédérés (1 par ville) · agrégation FedAvg pondérée par taille d'échantillon
- Manuel (5 rounds, Régression Linéaire) : R<sup>2</sup> = 0,412 vs 0,802 en centralisé → écart dû à la non-homogénéité (non-IID) des données entre villes
- Flower/Ray (10 rounds) : forte hétérogénéité par ville — R<sup>2</sup> de -0,40 (Casablanca) à 0,78 (Agadir)

## ARCHITECTURE & LIVRABLES

- src/{data, models, federated} · data/{raw, processed, checkpoints}
- models/{centralized, federated}/\*.pkl · visualizations/\*.png
- Datasets : air\_quality\_clean.csv, air\_quality\_scaled.csv

## CONCLUSION

Le Random Forest centralisé (R<sup>2</sup> = 0,966) reste le meilleur modèle pour ce volume de données. L'apprentissage fédéré valide le principe de confidentialité par conception, au prix d'une performance réduite par l'hétérogénéité inter-villes.